

Relatório do Projeto de Tópicos Avançados em Banco de Dados

Guilherme Andrade

May 2026

1 O problema

Problema: Análise e Classificação de Sentimento


Descrição: Dado um conjunto de dados de reviews e suas classificações, iremos analisar se enquadra em sentimento positivo ou negativo, além de classificar o quanto foi positivo ou negativo.

1.1 Escolha do DataSet

Foi escolhido o DataSet "Brazilian Portuguese Sentiment Analysis Datasets" para esse trabalho", mas especificamente o "b2w.csv", por conta de ser um dataset que já foi usado muitas vezes e ter materiais e aplicações feitas com ele para referência e análise, além de seu grande volume de dados.

2 Análise Exploratória

Como informações gerais obtidas do dataset temos:



index	original_index	review_text	review_text_processed	review_text_tokenized	polarity	rating	kfold_polarity	kfold_rating
0	11955	Bem macio e felpudo...recomendo. Preço imbatível e entrega rápida. Compraria outro quando precisar	bem macio e felpudo...recomendo. preço imbatível e entrega rápida. compraria outro quando precisar	['bem', 'macio', 'felpudo', 'recomendo', 'preço', 'imbatível', 'entrega', 'rápida', 'compraria', 'outro', 'quando', 'precisar']	1.0	4	1	1
1	35478	Produto excepcional! recomendo!!! inovador e gostoso de ler!!	produto excepcional! recomendo!!! inovador e gostoso de ler!!	['produto', 'excepcional', 'recomendo', 'inovador', 'gostoso', 'de', 'ler']	1.0	5	1	1
2	122760	recebi o produto antes do prazo mas veio com defeito na trava ou seja não dá para usar e até agora a Americanas não resolveu e preciso muito deste produto	recebi o produto antes do prazo mas veio com defeito na trava ou seja não dá para usar e até agora a americanas não resolveu e preciso muito deste produto	['recebi', 'produto', 'antes', 'do', 'prazo', 'mas', 'veio', 'com', 'defeito', 'na', 'trava', 'ou', 'seja', 'nao', 'da', 'para', 'usar', 'ate', 'agora', 'americanas', 'nao', 'resolveu', 'e', 'preciso', 'muito', 'deste', 'produto']	0.0	1	1	1
3	17114	Bom custo benefício. Adequado para pessoas que fazem um uso casual do aparelho . A máquina fotografica é excelente . A tela fornece imagens ótimas . Os recursos do aparelho são fáceis de manejar.	bom custo benefício. adequado para pessoas que fazem um uso casual do aparelho . a maquina fotografica e excelente . a tela fornece imagens otimas . os recursos do aparelho sao facéis de manejar.	['bom', 'custo', 'beneficio', 'adequado', 'para', 'pessoas', 'que', 'fazem', 'um', 'uso', 'casual', 'do', 'aparelho', 'a', 'maquina', 'fotografica', 'e', 'excelente', 'a', 'tela', 'fornece', 'imagens', 'otimas', 'os', 'recursos', 'do', 'aparelho', 'sao', 'facéis', 'de', 'manejar']	1.0	5	1	1
4	19112	Alem de higienico tem o tamanho ideal. Só faltou coher e garfo de sobremesa. Talvez se viesse com mais peças, eu gostaria mais.	alem de higienico tem o tamanho ideal. so faltou coher e garfo de sobremesa. talvez se viesse com mais pecas, eu gostaria mais.	['alem', 'de', 'higienico', 'tem', 'o', 'tamanho', 'ideal', 'so', 'faltou', 'coher', 'garfo', 'de', 'sobremesa', 'talvez', 'se', 'viesse', 'com', 'mais', 'pecas', 'eu', 'gostaria', 'mais']	NaN	3	-1	1

Figure 1:

Ou seja, temos aí 9 colunas com informações como `review_texts`, `reviews_texts_processed`, `reviews_texts_tokenized` que são os textos das reviews normais e eles processados e tokenizados, mas ainda iremos tratar eles com os métodos necessários. E o principal: o `rating`, que é a classificação referente ao produto que recebeu a review. Também temos a `polarity`, que dá uma nota de 1 ou 0 para as reviews, sendo 1 para positivo, que são com `rating` de 4 ou 5, e 0 para negativo, sendo `rating` de 1 ou 2. Mas não a iremos usar, pois ela não tem informação das reviews quem tem `rating` 3, o que jogaria fora muitos dados. Então iremos de começo criar uma nova coluna chamada `"sentiment_class"` que dá nota de 1 para classificação igual ou maior que 3 e 0 para as outras.

2.1 Escolha e definição de classes:

Escolhemos a classe `rating` e com ela definimos a classe `"sentiment_class"`, com ela podemos usar todos os dados para treinar os modelos.

2.2 Quantidade de Instâncias:

```
print("Total de instâncias: ")
data.shape

Total de instâncias:
(132373, 9)

data.info()

... <class 'pandas.core.frame.DataFrame'>
RangeIndex: 132373 entries, 0 to 132372
Data columns (total 9 columns):
#   Column                Non-Null Count  Dtype
---  ---
0   original_index         132373 non-null  int64
1   review_text            132373 non-null  object
2   review_text_processed  132373 non-null  object
3   review_text_tokenized  132373 non-null  object
4   polarity               116058 non-null  float64
5   rating                 132373 non-null  int64
6   kfold_polarity         132373 non-null  int64
7   kfold_rating           132373 non-null  int64
8   sentiment_class        132373 non-null  object
dtypes: float64(1), int64(4), object(4)
memory usage: 9.1+ MB
```

Figure 2:

2.3 Tabela Resumo:

```
... Palavras mais frequentes:  
de: 90117  
produto: 74739  
nao: 73223  
que: 65774  
muito: 53053  
do: 43736  
com: 43301  
para: 34479  
um: 34221  
bom: 26428  
da: 25945  
recomendo: 25220  
entrega: 24143  
no: 23889  
em: 23610  
na: 19698  
mas: 19537  
uma: 19225  
mais: 18980  
bem: 17359
```

Figure 3:

2.4 Distribuição das classes:




Figure 4:




Figure 5:




Figure 6:




Figure 7:

3 Tratamento e Pré-Processamento:

Nesta etapa, primeiro dividimos os dados entre teste e treino. A aplicação do pré-processamento após a divisão foi para garantir que não houvesse vazamento de dados.

Foram desenvolvidas funções modulares de limpeza para padronizar o corpus. O fluxo de tratamento incluiu:

Lowercase: Conversão de todos os caracteres para minúsculas e remoção de espaços excedentes.

Filtragem de Stopwords: Remoção de termos que não contribuem para a carga semântica do sentimento.

Posteriormente, implementamos um pipeline genérico para a extração de características utilizando três abordagens distintas: TF-IDF, Word2Vec e FastText. Enquanto o TF-IDF baseia-se na relevância estatística da frequência de termos, os modelos de embeddings (Word2Vec e FastText) buscam projetar as palavras em um espaço vetorial de baixa dimensão para capturar relações semânticas e sintáticas latentes.

4 Treinamento do modelo:

Dada ao tamanho do conjunto de dados (superior a 10.000 instâncias), para garantir a reprodutibilidade e a escalabilidade dos testes, foi desenvolvida uma função de treinamento parametrizada, capaz de adaptar a camada de entrada conforme a dimensionalidade de cada técnica de vetorização.

A arquitetura implementada seguiu o padrão que foi orientado. A camada de saída foi configurada com uma função de ativação Sigmoid, adequada para a classificação binária da polaridade do sentimento (positivo vs. negativo). Otimizou-se o modelo utilizando o algoritmo Adam, monitorando a métrica de acurácia e a função de perda binary crossentropy.

5 Análise e Comparação dos Resultados

Analisando as técnicas de vetorização, visto disparidades no desempenho da rede neural densa. Conforme observado nos experimentos, o método TF-IDF apresentou a maior acurácia entre os modelos testados.

Este fenômeno pode ser atribuído à natureza do corpus de avaliações de produtos. Em reviews, a polaridade do sentimento é frequentemente concentrada em termos específicos e repetitivos (ex: "excelente", "péssimo", "defeito"). O TF-IDF, ao penalizar termos comuns e valorizar palavras discriminantes através do cálculo de peso estatístico, obteve sucesso em mapear a intenção do usuário diretamente para a camada de entrada da rede.

Por outro lado, o Word2Vec apresentou um desempenho mais modesto. Sendo um modelo de representação distribuída, a estratégia de média de vetores utilizada para comprimir o documento pode ter resultado em uma perda de especificidade semântica, especialmente em avaliações que misturam elogios técnicos com críticas logísticas.

O FastText posicionou-se como um meio-termo eficiente. Sua superioridade em relação ao Word2Vec justifica-se pela análise de sub-word n-grams, que permite ao modelo capturar informações morfológicas e lidar de forma robusta com erros ortográficos, gírias e outros termos utilizados em redes sociais.

6 Texto Curto VS Texto Longo

Table 1: Comparação de Acurácia entre Texto Curto vs Longo

Texto Curto	Texto Longo
0.9296	0.8639

Para este teste, foi feita uma função para separar do dado de treino textos maiores e menores. Em seguida executamos uma função para comparar com o modelo e ver a sua acurácia. A escolha do modelo foi tf-idf, por conta de sua precisão e por ser o melhor para este contexto.

7 Resultados

Table 2: Comparação de Acurácia entre as Técnicas de Vetorização

Técnica de Vetorização	Acurácia no Teste
TF-IDF	0,9131
Word2Vec	0,8942
FastText	0,8937

1. O dataset representa bem o problema real?

Sim, por conta do seu grande volume de dados, das suas colunas com polarity, classificações. Sendo um dataset com ótimos e diversos exemplos.

2. TF-IDF superou embeddings? Por quê?

Sim, por causa de como TF-IDF trabalha (dando prioridade para termos repetidos e específicos), além de como dataset do problema é configurado. Visto que facilita muito o uso neste contexto.

3. A escolha de Dataset ajudou o treinamento de modelo?

Sim, por conta que este dataset além de ter um grande volume de dados e ser bem estruturado, ele tem várias aplicações feitas com ele, o que ajudou a ter uma base de uso com ele e também não tem muita discrepância de classes. E caso quiséssemos testar o modelo já de começo, poderíamos com as colunas que já veio com ele prontas.

4. O modelo apresentou overfitting?

Não, por causa de como o dataset está configurado e da divisão que foi feita e pelo grande volume de dados.

5. O melhor resultado compensou o custo computacional?

Sim, pois foi um custo computacional barato pelo resultado. Mais uma vez, por conta do dataset ser de reviews, que são textos curtos com muitas palavras repetidas.

6. Quais limitações foram observadas?

Por conta de serem reviews, via-se uma dificuldade em busca de textos longos, além de uma falta de reviews mais diferenciadas, com um vocabulário diferente, ou que fuja do espectro da maioria.

7. Como o trabalho poderia evoluir?

Poderia evoluir buscando reviews de produtos ou nichos específicos. Além de poder ser feita uma comparação com o quanto a pessoa escreve (tamanho da review) e o sentimento da review. Também poderia ir para um lado de qual é o maior problema, o que mais traz sentimentos negativos (entrega atrasada, frustração com o produto).